

Classificação de equipamentos da telefonia móvel utilizando BOVW e aprendizado supervisionado

Maria Eduarda Alves da Silva, Lylian Kelly de Siqueira Gomes

Resumo— A influência causada pela pandemia da covid-19, possibilitou o crescimento do número de acessos móveis no Brasil, alterando o cenário de decréscimo visto desde 2015. Atrélado a este fato, a produção de relatórios fotográficos na telefonia móvel, etapa predecessora impeditiva para a implantação de novos equipamentos, tende a aumentar, demandando mais recursos humanos para analisar e tomar decisões, considerando as informações contidas nos documentos. O objetivo deste trabalho é viabilizar a aplicação do modelo BOVW, responsável pela construção de palavras-visuais, introduzindo seu resultado em algoritmos de aprendizado de máquina supervisionado para classificação de equipamentos da telefonia móvel. Os resultados obtidos atingiram valores de 28% de média de acurácia para o conjunto de imagens com 50% de treino e 50% de teste.

Palavras-Chave—Classificação de equipamentos da telefonia móvel, palavras-visuais, aprendizado de máquina supervisionado.

Abstract— The influence caused by the covid-19 pandemic, enabled the growth of the number of mobile accesses in Brazil, changing a scenario of decline seen since 2015. Linked to this fact, the production of photographic reports in mobile telephony tends to increase, demanding more responsible human resources for the analysis and decision-making of the information contained in the documents. The objective of this work is to enable the application of the BOVW model, responsible for the construction of visual words, introducing its result in supervised learning algorithms for classification of mobile telephony equipment. The obtained results reached values of 28% of the average accuracy for the set of images with 50% of training and 50% of test.

Keywords— Classification of mobile telephony equipment, visual words, supervised machine learning.

I. INTRODUÇÃO

Desde 2015 o mercado de telefonia móvel no Brasil veio registrando a redução do número de acessos móveis. Este cenário sofreu uma recente alteração através de um crescimento mensal iniciado em julho de 2020, tendo em dezembro um acréscimo de 3,26% em comparação com o mesmo mês do ano anterior. Um dos principais vetores para este crescimento foi a pandemia da Covid-19, que fomentou a necessidade das quatro maiores companhias de telecomunicações do país, sendo elas: TIM, OI, CLARO e VIVO, responsáveis por 96,9 % do total de acessos, a manterem a qualidade do serviço e ao mesmo tempo ampliar a capilaridade de sua infraestrutura [1].

De acordo com a Agência Nacional de Telecomunicações (ANATEL), espera-se que para garantir a cobertura de novas tecnologias no Brasil como para a entrada do 5G, em 31 de julho das 2022 às 26 capitais e o Distrito Federal deverão obter uma Estação Rádio Base (ERB) a cada 100 mil habitantes [2]. Assim, o volume da instalação de novos equipamentos para acesso móvel é um ponto relevante para o cenário de telecomunicações do país.

Antes da instalação de uma nova ERB, é necessário realizar uma vistoria e elaborar um relatório fotográfico chamado *Technical Site Survey Report* (TSSR). No TSSR é descrita a atividade que será executada em campo, assim como as informações estruturais do local e dos equipamentos existentes. Após a instalação dos equipamentos, é elaborado o relatório fotográfico *Field Activity Monitoring* (FAM), onde é documentada a implantação da obra. Para aprovação da instalação são checados os itens referentes a estrutura física, o inventário da ERB e verificado se estão de acordo com o TSSR. Atualmente esse processo é executado de forma manual.

Levando em consideração o incremento da geração e aprovação de relatórios devido à crescente demanda com a chegada do 5G, cria-se uma oportunidade para o desenvolvimento de algoritmos voltados a visão computacional que atuem na classificação, auxílio na tomada de decisão e controle no processo de análise fotográfica que, atualmente, demanda recursos humanos.

Neste contexto, o presente trabalho tem como principal objetivo a aplicação do *Bag of Visual Words* (BOVW) com o intuito de produzir palavras-visuais referentes as imagens de 4 equipamentos e/ou itens encontrados nos relatórios FAM de instalação disponibilizados pela empresa *Telecom Italia* (TIM SA). As palavras-visuais produzidas, serão introduzidas nos algoritmos de classificação Máquinas de Vetores de Suporte (*Support Vector Machine* - SVM) e Redes *Perceptron* Multicamadas (*Multilayer Perceptron* - MLP) para análise comparativa do desempenho de cada modelo no processo de classificação dos itens selecionados. Através da técnica *Grid Search*, foi desenvolvido um estudo combinatório dos hiperparâmetros utilizados nos algoritmos de classificação para escolha da melhor combinação detentora do maior *score* de acurácia.

Este artigo segue a divisão das seções da seguinte maneira: na Seção II encontra-se o referencial teórico, detalhando o modelo BOVW, os algoritmos de classificação, a técnica de otimização dos hiperparâmetros e as métricas de avaliação. A Seção III apresenta a metodologia aplicada para implementação do sistema de classificação dos itens. A Seção

IV traz a discussão e os resultados encontrados. E, por fim, a Seção V descreve as conclusões do estudo.

II. REFERENCIAL TEÓRICO

A. Bag of Visual Words

O modelo *Bag of visual Words* (BOVW) é uma derivação da técnica de extração de informações em texto (*Bag of Words*), implementada com o objetivo de construir palavras-visuais que representem regiões similares encontradas no agrupamento de descritores locais extraídos das imagens [3]. A seguir, o processo de implementação do BOVW será discutido detalhadamente.

1) Extração de características

As características (*features*) correspondem a representação de um conjunto de informações obtida em uma grande quantidade de dados. Para que uma determinada representação funcione bem, ela deve permitir uma fácil classificação e conter uma sensibilidade suficiente para detectar e diferenciar pontos de semelhança [5].

Um descritor de características é responsável por selecionar e representar numericamente a característica encontrada numa imagem. Sendo assim, de maneira geral, um descritor deve permitir o reconhecimento de padrões apesar de mudanças de escala, orientação, formato e iluminação [5]. Os descritores podem ser classificados em dois tipos, sendo eles globais e locais. Os descritores globais geram um único vetor de características que representa toda imagem analisada, em contrapartida os locais são capazes de produzir para cada região de interesse um vetor de característica.

Os algoritmos de extração de características SIFT e ORB podem ser utilizados para geração de descritores locais.

• SIFT

Scale Invariant Feature Transform (SIFT) é um algoritmo de extração de características proposto por Lowe [6] amplamente utilizado na visão computacional para classificação e reconhecimento de objetos. O SIFT é invariante a translações, rotações e transformações de escala, atendendo a robustez para mudanças de perspectiva e iluminação [5]. Através dele, são detectados pontos de interesse ou pontos chave (*keypoints*) por meio do cálculo de diferenças gaussianas (*Difference of Gaussians* - DOG) e são formados descritores numericamente representados por vetores de tamanho 128 baseado nos histogramas de gradientes orientados para descrever a vizinhança dos pontos de interesse.

• ORB

Oriented FAST and Rotated BRIEF (ORB) foi desenvolvido para atuar em ambientes com baixa capacidade computacional ou que necessitem de processamento em tempo real [5]. O ORB atende aos requisitos de invariância a rotação e robustez ao lidar com ruídos. Sua estrutura é baseada na junção de dois algoritmos, sendo eles o FAST que atua na detecção de pontos de interesse e o BRIEF que produz os descritores de características.

2) Representação de palavras-visuais

A construção das palavras-visuais se baseia na aplicação de técnicas de agrupamento nos descritores locais das imagens, sendo o K-means o modelo mais utilizado. O objetivo deste

algoritmo é particionar um conjunto de pontos entre k subconjuntos disjuntos capazes de maximizar a distância intergrupos e diminuir a distância intragrupos [4]. Com isto, cada grupo origina um centróide que representa a palavra inserida no dicionário – visual. O valor configurado para a quantidade de palavras-visuais obtido através dos k -clusters na execução do k-means é comumente definido de maneira empírica [4].

O processo de codificação (*coding*) é iniciado através da abordagem *hard assignment* ou *nearest neighbor*. Nesta etapa, a palavra-visual que possui a menor distância ao vetor de características é selecionada e adiciona-se uma unidade ao bin correspondente a essa palavra-visual no histograma [4]. Em seguida, a fase de sumarização (*pooling*) é implementada visando sintetizar em um único vetor de características a representação final da imagem por meio da técnica *sum-pooling*. Assim, um histograma de palavras-visuais é gerado de acordo com a soma das ocorrências de cada palavra-visual na imagem. Posteriormente, o histograma será normalizado com o intuito de obter um valor médio 0 e um desvio padrão de 1 servindo de entrada para os algoritmos de classificação.

A Figura 1 demonstra o processo de aplicação das etapas de codificação e sumarização, sendo inicializada por meio da detecção de pontos-de-interesse através do agrupamento das características locais da bicicleta. Com os *keypoints* devidamente agrupados, é realizada a construção do dicionário-visual que possibilita o reconhecimento de similaridades entre as características e atribuição de suas palavras correspondentes pertencentes ao conjunto {A, B, C}. Após esta fase, se torna possível a quantização e criação de um histograma que retorne a frequência da ocorrência de cada palavra-visual definida, representando, por fim, a imagem da bicicleta.




Fig. 1. Etapas do modelo BOVW [4]

B. Algoritmos de classificação de imagens

O aprendizado de máquinas (*Machine Learning*) aplicado ao processamento de imagens está diretamente relacionado com o ramo da visão computacional. Os algoritmos pertencentes a esta área constroem processos que são capazes de extrair informações, reconstruir, classificar e reconhecer objetos a partir do conjunto de pixels localizados nas imagens [7].

O processo de classificação pode ser desenvolvido por meio de algoritmos supervisionados e não-supervisionados, sendo o primeiro aquele que obtém um conhecimento prévio

acerca das classes associadas ao conjunto de dados e o segundo aquele que não contém informações previamente rotuladas.

Os algoritmos SVM e MLP são exemplos de classificadores do tipo supervisionados.

1) Máquinas de Vetores de Suporte

Uma Máquina de vetor de Suporte (*Support vector Machine* - SVM) é um modelo de aprendizado de máquina supervisionado. Sendo assim, necessita da figura de um professor externo, o qual apresenta o conhecido do ambiente por conjuntos de exemplos na forma: entrada, saída desejada. O objetivo é produzir uma representação que seja capaz de classificar corretamente as novas entradas não apresentadas previamente [8]. Esse tipo de modelo é adequado para a classificação de conjuntos de dados complexos, porém de pequeno ou médio porte [9].

As SVMs são classificadores discriminatórios que atuam na separação de padrões por meio de hiperplanos. Em outras palavras, dado um conjunto de amostras rotuladas para treino, o algoritmo busca ótimos hiperplanos para categorizar as amostras de teste [10]. Este hiperplano deve ser capaz de proporcionar uma distância mínima sobre o conjunto de treino, sendo esta distância denominada de margem. Portanto, um ótimo hiperplano maximiza a margem do conjunto de treino.

2) Redes Perceptron Multicamadas

As Redes Perceptron Multicamadas (MLP), são redes do tipo *feedforward* caracterizadas por conter mais de uma camada intermediária, também conhecidas como camadas escondidas (*hidden layers*), situadas entre a camada de entrada e a respectiva camada neural de saída [11].

A rede MLP, utiliza o conceito de *backpropagation* em seu conjunto de treino, o qual corresponde a um algoritmo de aprendizado supervisionado. O seu objetivo é otimizar os pesos para que a rede neural possa aprender a mapear corretamente as entradas arbitrárias para as respectivas saídas.

O seu aprendizado desenvolvido pode ser dividido em duas etapas, as fases *forward* e *backward*. Na fase *forward*, os sinais de entrada percorrem toda a rede visando alcançar a camada de saída sendo multiplicados pelos seus correspondentes pesos, os quais são inicializados randomicamente no intervalo de 0 a 1. A fase *backward* se inicia a partir do cálculo do erro da saída após a chegada do sinal nesta camada. Seu principal objetivo é minimizar o erro variando o peso [11].

C. Otimização de modelos através de hiperparâmetros

Visando atingir melhores desempenhos na aplicação dos modelos de aprendizado de máquina, algumas técnicas de otimização foram desenvolvidas levando em consideração aspectos importantes na construção de cada algoritmo.

A técnica *Grid Search* possibilita a implementação de testes combinatórios dos hiperparâmetros definidos para cada modelo de aprendizado de máquina [12]. Seu objetivo é encontrar o valor referente ao melhor *score* obtido dentre o conjunto de combinações treinado, sendo este correspondente ao tipo de métrica configurada, como exemplo a acurácia.

Para modelos como SVM podem ser considerados os parâmetros correspondentes a margem e o tipo de *kernel*, assim como para os modelos de Redes Neurais a taxa de aprendizagem e a função de ativação são pontos a serem observados.

D. Métricas de avaliação

A avaliação dos modelos de aprendizado de máquina consiste na verificação do resultado obtido através de diferentes tipos de métricas. Através delas, se torna possível compreender o comportamento do modelo, possibilitando a execução de ajustes que retornem melhores taxas de assertividade dos valores previstos.

Dentre as métricas existentes algumas ganham destaque, sendo elas:

1) Acurácia

Reflete o percentual de acerto dos valores previstos, sendo comumente utilizada como índice da performance geral do modelo [13].

2) Matriz de confusão

A matriz de confusão é uma tabela composta pela quantidade de acertos e erros do modelo em comparação com o resultado esperado [13]. Espera-se encontrar os maiores valores na diagonal da tabela, pois refletem o nível de assertividade do modelo para cada classe previamente definida.

3) Precisão e Revocação

A precisão (*precision*) e a revocação (*recall*) são métricas calculadas a partir do conjunto de verdadeiro positivo, falso negativo, falso positivo e verdadeiro negativo dos dados previstos.

Através da precisão é possível identificar o percentual de acerto dos valores previstos a partir do conjunto de falsos positivos e verdadeiros positivos. Assim, ela pode ser utilizada para identificar se de todos os objetos classificados pertencentes a um determinado grupo quantos realmente fazem parte deste grupo.

Por meio da revocação o percentual de acertos é obtido levando em consideração o conjunto dos falsos negativos e verdadeiros positivos. Com isto, ela parte do perímetro de objetos que efetivamente pertencem a uma classe com o intuito de obter a proporção da quantidade de valores que o algoritmo foi capaz de identificar como membro desta classe.

III. METODOLOGIA

Nesta seção será apresentado o processo utilizado na composição do banco de imagens como também a descrição dos experimentos efetuados.

A. Banco de imagens

As imagens adquiridas para o desenvolvimento do projeto foram disponibilizadas pela empresa de telecomunicações TIM SA através dos relatórios fotográficos FAM de instalação. Foram utilizados 168 arquivos, originalmente no formato HTML (*Hypertext Markup Language*). Cada relatório é composto em média por 100 itens distribuídos em textos e imagens, porém para o trabalho foram escolhidos os itens: gabinete de instalação com porta fechada e porta aberta, cabo de aterramento da *Baseband Unit* (BBU) e equipamento de *Global Positioning System* (GPS), conforme ilustrado na Figura 2.

Inicialmente foi utilizado um algoritmo construído em linguagem Python para extração das imagens dos 4 itens de interesse. O *script* desenvolvido identifica os campos de interesse, seleciona-os e em seguida armazena cada imagem em pastas designadas com o respectivo nome do item. Devido

a diversificação da versão dos FAMs de instalação utilizados, apenas 426 imagens foram extraídas, sendo 107 de gabinete de porta fechada, 112 gabinete de porta aberta, 105 cabo de aterramento da BBU e 102 instalação de GPS.



Fig. 2. Conjunto de imagens geradas

Em seguida, as imagens passaram por técnicas de processamento digital através da aplicação de um *script* em Python utilizando a biblioteca de programação em código aberto *Opencv* [14]. O procedimento consistiu na leitura de cada item, redimensionamento, filtragem bilateral de suavização e remoção de ruídos.

Foram realizados três cenários, alterando-se o percentual da quantidade de imagens utilizadas para treino e teste dos algoritmos de classificação SVM e MLP. No cenário 1 foram utilizadas 80% das imagens para treino e 20% para teste, no cenário 2: 50% para treino e 50% para teste e no cenário 3: 60% para treino e 40% para teste, resultando no quantitativo de imagens detalhadas nas Tabelas I, II e III, respectivamente.

TABELA I. CENÁRIO 1 (80% TREINO E 20% TESTE)

Itens de classificação	Treino	Teste	Total
Cabo de aterramento da BBU	84	21	105
Gabinete de porta aberta	90	22	112
Gabinete de porta fechada	86	21	107
Instalação do GPS	82	20	102
Total	342	84	426

B. Implementação dos algoritmos

As etapas de implementação dos algoritmos estão representadas no fluxograma da Figura 3.

TABELA II. CENÁRIO 2 (50% TREINO E 50% TESTE)

Itens de classificação	Treino	Teste	Total
Cabo de aterramento da BBU	54	51	105
Gabinete de porta aberta	56	56	112
Gabinete de porta fechada	54	53	107
Instalação do GPS	51	51	102
Total	215	211	426

TABELA III. CENÁRIO 3 (60% TREINO E 40% TESTE)

Itens de classificação	Treino	Teste	Total
Cabo de aterramento da BBU	63	42	105
Gabinete de porta aberta	67	45	112
Gabinete de porta fechada	64	43	107
Instalação do GPS	61	41	102
Total	255	171	426




Fig. 3. Fluxograma da implementação dos algoritmos

1) Etapa I

A aprendizagem é iniciada a partir da aplicação do modelo BOVW, tendo como primeira ação os extratores de características SIFT e ORB introduzidos no conjunto de treino de cada subdivisão. A quantidade de 150 pontos de interesse foi configurada para o SIFT e ORB, sendo produzidos seus respectivos descritores locais. Em seguida, o processo de agrupamento foi implementado por meio do *k-means*, com o valor de 200 *k-clusters* utilizados para geração dos centróides e construção das palavras-visuais.

Com a conclusão da formação do dicionário-visual por meio da fase de codificação, a associação de cada descritor de características com sua respectiva palavra-visual foi efetuada. Consequentemente, desdobrando-se para a sumarização da representação da imagem em apenas um vetor de características por meio do histograma de palavras-visuais, levando em consideração a padronização dos dados conforme apontado na Seção II.A.2.

2) Etapa II

Posterior a conclusão da Etapa I, os algoritmos de classificação SVM e MLP receberam o histograma de palavras-visuais relacionados com cada subconjunto de imagens para treino, sendo inicializados através da biblioteca em Python de código aberto *sklearn* [15]. Os hiperparâmetros utilizados estão demonstrados na Tabela IV.

TABELA IV. HIPERPARÂMETROS DOS MODELOS DE CLASSIFICAÇÃO

Modelos	Parâmetros		
SVM	Kernel	Gama	-
MLP	Função de ativação	Nº máximo de iterações	Solver

O SVM recebeu o *kernel* que têm a finalidade de projetar os vetores de características de entrada em um espaço de características de alta dimensão para classificação de problemas que se encontram em espaços não linearmente separáveis [16]. O gama é um coeficiente do próprio kernel.

Para a rede MLP, a função de ativação é responsável por calcular os valores correspondentes aos nós de cada camada escondida da rede [17]. O número máximo de iterações define a quantidade limite de iterações que deve ocorrer no modelo. E, por último, o *solver* auxilia no processo de otimização dos pesos, sendo executado até o modelo convergir ou atingir o número máximo de iterações definido.

Conforme o fluxograma, a técnica *grid search* foi aplicada para ambos os modelos introduzindo a testagem das combinações de parâmetros, baseado na interação dos extratores de características e os modelos, tendo em vista o retorno do melhor *score* de acurácia.

Partindo do encontro das melhores combinações de cada modelo, os subconjuntos de teste foram introduzidos nas etapas de extração de características, agrupamento e construção do histograma de palavras-visuais para realização da classificação. Tais processos foram executados 5 vezes para cada subdivisão do conjunto das imagens, sendo utilizado como resultado os cenários com melhor média do valor de acurácia para avaliação comparativa do desempenho dos algoritmos de classificação SVM e MLP.

Foram verificadas além da métrica de acurácia, a precisão, revocação e a matriz de confusão produzidos nas iterações entre as etapas I e II de acordo com os subconjuntos de imagens utilizadas. Também foi analisado o tempo médio total gasto na execução do processo de extração de características do SIFT e ORB.

IV. DISCUSSÃO E RESULTADOS

A partir das 5 repetições efetuadas para cada subconjunto de imagens, foi verificado o desempenho dos algoritmos por meio das métricas de acurácia, precisão e revocação. Os resultados da acurácia média obtidos nos cenários 1 (80% treino e 20% teste), 2 (50% treino e 50% teste) e 3 (60% treino e 40% teste) combinando os algoritmos de descrição de características SIFT e ORB e de classificação dos objetos SVM e MLP estão detalhados na Tabela V.

No cenário 1 o classificador SVM juntamente com o extrator de características SIFT obteve o melhor desempenho, retornando 26% do valor médio de acurácia em comparação

com as demais combinações. No cenário 2 o melhor resultado obtido foi entre o classificador MLP e extrator ORB, com 28% de acurácia. E, por fim, no cenário 3 o classificador SVM com o extrator SIFT retornou o maior valor de acurácia, 25%.

Os valores de acurácia média alcançados para todas as combinações do modelo e extrator ficaram estacionados no intervalo de 20% a 40%, não apresentando grandes variações. Para o conjunto 1, composto pelo maior número de imagens para treino, foi possível identificar que os valores de acurácia retornados nos três primeiros índices de repetição ficaram acima ou igual a 30%. Em contrapartida, nos conjuntos 2 e 3 apenas em um índice de repetição foi encontrado um valor de acurácia acima de 30%, sendo eles 36% e 31% respectivamente. Este fato indica que a quantidade de dados incluso no processo de aprendizagem interfere no percentual de assertividade da classificação dos modelos.

TABELA V. TAXAS DE ACURÁCIA DOS CONJUNTOS DE TESTE

Imagens	Índice de repetição	Acurácia (%)			
		SVM x SIFT	SVM x ORB	MLP x SIFT	MLP x ORB
Conjunto 1	1	29	17	36	20
	2	32	25	20	23
	3	25	24	27	30
	4	25	27	19	21
	5	21	24	25	26
	Média	26	23	25	24
Conjunto 2	1	23	24	20	29
	2	19	29	19	24
	3	21	29	19	24
	4	24	27	24	36
	5	23	27	25	28
	Média	22	27	21	28
Conjunto 3	1	21	23	20	20
	2	19	25	21	26
	3	31	25	28	27
	4	27	25	28	24
	5	27	19	25	23
	Média	25	23	24	24

Espera-se encontrar valores de acurácia acima de 50% pois quanto maior a taxa, melhor o índice de assertividade do classificador. Na Tabela V, através dos valores descritos, observou-se que os modelos não conseguiram classificar com maior assertividade os subconjuntos de teste. As variações intrínsecas aos valores definidos para os parâmetros, assim como o número de imagens utilizadas para o treino e reconhecimento podem estar associados ao baixo desempenho dos modelos.

As Figuras 4, 5 e 6 demonstram a matriz de confusão correspondente aos 3 subconjuntos de imagens que obtiveram o melhor valor de acurácia entre as 5 iterações, demonstrado na Tabela V. Para o conjunto 1, foi identificado na primeira iteração o valor de 36% de acurácia com o MLP e SIFT. No conjunto 2, na quarta iteração, o valor do MLP e ORB produzido foi de 36% de acurácia e para o conjunto 3, na terceira iteração, o SVM e SIFT gerou 31%.

O eixo vertical representa as verdadeiras *labels*, sendo 0 – cabo de aterramento da BBU, 1 – gabinete de porta aberta, 2 – gabinete de porta fechada e 3 – instalação do GPS. O eixo

horizontal representa os valores previstos, seguindo a mesma legenda anteriormente descrita.




Fig 4. Matriz de confusão - Conjunto 1 (MLP x SIFT)




Fig 5. Matriz de confusão - Conjunto 2 (MLP x ORB)




Fig 6. Matriz de confusão - Conjunto 3 (SVM x SIFT)

A análise da Figura 4 mostra que os itens referentes ao gabinete de porta aberta e fechada obtiveram os melhores resultados com 8 itens classificados corretamente. Em contrapartida o pior resultado encontrado se refere ao item do GPS que dos 20 analisados, apenas 6 foram classificados corretamente.

Para a Figura 5, os itens do gabinete de porta aberta e GPS obtiveram maior assertividade atingindo mais de 17 itens classificados corretamente. Tendo seu pior desempenho com o gabinete de porta fechada retornando 14 itens corretos num conjunto de 53.

Na Figura 6, pode-se visualizar que os três primeiros itens obtiveram os melhores retornos com valores acima de 13, tendo apenas o GPS com menor valor de 9 classificações

corretas. Com isto, pode-se inferir que o gabinete de porta aberta e fechada juntamente com o aterramento da BBU apresentaram em maioria os melhores valores de assertividade na matriz de confusão.

A precisão e revocação estão ilustradas na Figura 7, onde no eixo vertical tem-se o intervalo de valores obtidos entre as duas métricas e no eixo horizontal está descrito os 4 itens de classificação legendados de acordo com a mesma visão apresentada na matriz de confusão, sendo 0 – cabo de aterramento da BBU, 1 – gabinete de porta aberta, 2 – gabinete de porta fechada e 3 – GPS. A linha laranja representa a métrica de revocação, e a linha azul a de precisão. O cenário utilizado para geração do gráfico é composto pelos valores de precisão e revocação de cada conjunto de imagens com melhor resultado de acurácia gerado entre as 5 iterações demonstradas na Tabela V.




Fig 7. Relação de Precisão e Revocação dos itens de classificação

Observou-se que no conjunto 1 a classe do GPS apresentou o melhor valor de precisão e o pior de revocação. No conjunto 2, o gabinete de porta aberta obteve para ambas as métricas os melhores valores. E, no conjunto 3 o cabo de aterramento da BBU apresentou o melhor valor de revocação em contrapartida o gabinete de porta aberta obteve o melhor valor de precisão.

Para todos os conjuntos de imagens também foi avaliado o tempo total médio de processamento dos algoritmos de extração de características SIFT e ORB, levando em consideração o treino e teste dos modelos, conforme detalhado na Tabela VI.

TABELA VI. DISTRIBUIÇÃO DO TEMPO DE EXECUÇÃO DO SIFT E ORB

Conjunto de imagens	Índice de repetição	Tempo (s)	
		SIFT	ORB
Conjunto 1 (80% treino e 20% teste)	1	48,9	12,6
	2	26,8	6,9
	3	31,3	6,8
	4	34,8	7,3
	5	43,4	8,2
	Média	37,04	8,36
Conjunto 2 (50% treino e 50% teste)	1	45,6	9,85
	2	39,0	5,2

50% teste)	3	21,7	4,95
	4	21,4	5,03
	5	22,4	4,96
	Média	30,02	6
Conjunto 3 (60% treino e 40% teste)	1	22	5,64
	2	21,4	5,06
	3	21,7	5,04
	4	22,8	5,19
	5	21,8	4,93
	Média	21,94	5,17

Observou-se que o tempo médio total gasto de processamento cresceu de acordo com o aumento do conjunto de treino aplicado aos extratores de características. Isto indica que quanto mais imagens forem incluídas na etapa de aprendizagem dos modelos, os extratores irão passar mais tempo realizando o processo de geração dos descritores locais.

O melhor tempo médio total gasto pelo SIFT foi visto no conjunto 3 de imagens com 21,94 segundos. Para o ORB, o melhor tempo médio encontrado obteve 5,17 segundos, também participante do conjunto 3 de imagens. Este cenário comprova a finalidade do algoritmo ORB desenvolvido para atuar em ambientes com baixa capacidade computacional ou que necessitem de processamento em tempo real.

V. CONCLUSÕES

O presente trabalho foi desenvolvido buscando atingir o objetivo da aplicação do modelo de BOVW atrelado aos algoritmos de classificação supervisionada para reconhecimento de 4 itens provenientes dos relatórios fotográficos FAM de instalação, sendo eles: cabo de aterramento da BBU, gabinetes com porta aberta e fechada e a presença do equipamento GPS. O modelo MLP juntamente com o extrator de características ORB obteve o melhor desempenho retornando 28% de acurácia média utilizando 50% treino e 50% teste no processo de aprendizagem e classificação. A matriz de confusão apresentou maior assertividade para os itens do gabinete de porta aberta e fechada juntamente com o cabo de aterramento da BBU considerando as três subdivisões do conjunto de imagens sendo, respectivamente, 80% treino e 20% teste, 50 % treino e 50 % teste e 60% treino e 40% teste.

Sobre as métricas de precisão e revocação, seus melhores desempenhos foram encontrados no conjunto 1 (80% treino e 20% teste) e 2 (50% treino e 50% teste), referentes aos itens do GPS e gabinete de porta aberta retornando valores de 50% e 52%, respectivamente. E, no conjunto 3 foi obtido o menor tempo médio com 5,17 segundos de processamento gasto na etapa de extração de características promovida pelo SIFT e ORB.

Os valores alcançados abrem margem para o desenvolvimento de otimizações em trabalhos futuros através da aplicação de técnicas que considerem a introdução do conceito de *deep learning* por meio das Redes Neurais Convolucionais, partindo do conjunto de novas imagens coletadas nos relatórios FAM de instalação. Espera-se que o processo iniciado possa complementar o conteúdo de demais trabalhos acadêmicos voltados ao setor de telecomunicações, especificamente na área de telefonia móvel.

AGRADECIMENTOS

Agradeço a Deus por se fazer presente em todos os momentos, aos meus familiares pelo suporte dado ao longo da graduação, principalmente a minha mãe Edilene Monteiro. Aos meus líderes, tutores e colegas de trabalho da empresa TIM SA por sempre incentivarem e acreditarem no meu potencial.

Gostaria de agradecer a Jéssica Moura pelo carinho e reciprocidade, Beatriz Alves pelas conversas divertidas, Tábatha Morgana pelos melhores conselhos, Diego Santos pelas risadas, Anyelle Manuele pelas brincadeiras, Thaís Silva pela amizade e Wandrey Donato pela irmandade.

Também gostaria de agradecer, especialmente, as minhas amigas de curso Jamila Abid e Beatriz Rochana pelo suporte, parceria e cumplicidade em toda jornada de graduação, sendo essenciais para meu desenvolvimento pessoal e profissional.

Por fim, também gostaria de agradecer a todos os professores que compartilharam seus conhecimentos a respeito do vasto ramo da engenharia elétrica de telecomunicações, em especial a professora Lylian Gomes pela disponibilização, troca de experiências e orientação do projeto final de curso.

REFERÊNCIAS

- [1] *Anatel divulga relatório da telefonia móvel relativo a 2020*. (2021, Out. 17) [Em linha]. Disponível em: <https://www.gov.br/anatel/pt-br/assuntos/noticias/anatel-divulga-relatorio-da-telefonia-movel-relativo-a-2020>
- [2] A.F. Jr. (2021, Out. 19). *Guia do 5G: quando a tecnologia chegará ao Brasil? Veja perguntas e respostas*. [Em linha]. Disponível em: <https://g1.globo.com/economia/tecnologia/noticia/2021/03/12/guia-do-5g-quando-a-tecnologia-chegara-ao-brasil-veja-perguntas-e-respostas.ghtml>
- [3] A. Silva, A. Silva e G.D. Defreitas, "Reconhecimento de Produtos por Imagem Utilizando Palavras Visuais e Redes Neurais Convolucionais", Universidade do Estado de Santa Catarina, 2014. Consult. 2021-12-10. Doi: 10.1109/CVPRW.2014.131. [Em linha]. Disponível em: https://www.researchgate.net/publication/275959017_Reconhecimento_de_Produtos_por_Imagem_Utilizando_Palavras_Visuais_e_Redes_Neurais_Convolucionais
- [4] G.V. Pedrosa, "Caracterização e recuperação de imagens usando dicionários visuais semanticamente enriquecidos", Universidade de São Paulo, 2015. Consult. 2021-11-14. [Em linha]. Disponível em: <http://www.teses.usp.br/teses/disponiveis/55/55134/tde-19122015-120703/>
- [5] J. Xavier e A. Ferreira, "Uso de algoritmos de extração de características para seguir nuvens", *Revista de Ciência, Tecnologia e Humanidades do IFPE*, vol. 9, n.º 2, 2017. Consult. 2021-10-17. [Em linha]. Disponível em: <http://revistas.ifpe.edu.br/index.php/cientec/article/view/123>
- [6] D.G. Lowe, "Distinctive Image Features from Scale-Invariant Keypoints", *International Journal of Computer Vision*, vol. 60, n.º 2, pp. 91-110, nov. 2004. Consult. 2021-11-16. [Em linha]. Disponível em: <https://doi.org/10.1023/B:VISI.0000029664.99615.94>
- [7] J. Lacerda. (2021, Dez. 7). *Visão computacional: conheça as aplicações e a importância para a transformação digital*. [Em linha]. Disponível em: <https://certi.org.br/blog/visao-computacional/>
- [8] A.C. Lorena e A.C.P.L.F. De Carvalho, "Uma introdução às support vector machines", *Revista de Informática e Teórica e Aplicada*, vol. 14, n.º 2, pp. 43-67, nov. 2007. Consult. 2021-11-15. [Em linha]. Disponível em: <https://doi.org/10.22456/2175-2745.5690>
- [9] A. Géron, *Mãos à obra: Aprendizado de máquina com Skit-learn & tensorflow*, 1º ed. Rio de Janeiro, Brasil: Alta Books, 2019, pp. 149-169.
- [10] O. Documentation, *Introduction to support vector machines — opencv 2.4.13.0 documentation*. Consult. 2021-11-4. [Em linha]. Disponível em: http://docs.opencv.org/2.4/doc/tutorials/ml/introduction_to_svm/introduction_to_svm.html
- [11] J. Massucatto, "Aplicação de conceitos de redes neurais convolucionais na classificação de imagens de folhas", Universidade Tecnológica Federal do Paraná, 2018. Consult. 2021-11-17. [Em linha]. Disponível em: http://repositorio.roca.utfpr.edu.br/jspui/bitstream/1/11013/1/PB_COEN_C_2018_1_03.pdf

- [12] A.L. Vaz. (2021,Nov. 16). *Otimizando os hiperparâmetros*. medium.com.[Em linha].Disponível em: <https://medium.com/data-hackers/otimizando-os-hiperpar%C3%A2metros-621de5e9be37>.
- [13] V. Rodrigues. (2021,Dez. 8). *Métricas de Avaliação:acurácia,precisão,recall...quais as diferenças?*. [Em linha]. Disponível em: <https://vitorborbarodrigues.medium.com/m%C3%A9tricas-de-avalia%C3%A7%C3%A3o-acur%C3%A1cia-precis%C3%A3o-recall-quais-as-diferen%C3%A7as-c8f05e0a513c>
- [14] A. Mordvintsev e A. K. *OpenCV-Python Tutorials Documentation*, 1 ed. (2017). Consult. 2021-10-17. [Em linha]. Disponível em: https://opencv24-python-tutorials.readthedocs.io/_/downloads/en/stable/pdf/
- [15] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python", *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011
- [16] G. Medeiros, "Máquina de Vetores Suporte: estudo e análise de parâmetros para otimização de resultado", Universidade Federal de Pernambuco,2010. Consult. 2021-11-16. [Em linha]. Disponível em: <https://www.cin.ufpe.br/~tg/2010-2/gmoj.pdf>
- [17] D. Matos. (2021,Nov. 16).*Customizando Redes Neurais com Funções de Ativação Alternativas*. [Em linha]. Disponível em: <https://www.cienciaedados.com/customizando-redes-neurais-com-funcoes-de-ativacao-alternativas/>